

La unidad que falta: la falacia mereológica y el argumento del sustrato

Autor: Steven Vallejo Ortiz **Curso:** Filosofía de las Neurociencias (2026-1) **Profesor:** Santiago Arango-Muñoz **Institución:** Instituto de Filosofía, Universidad de Antioquia

Introducción

Bennett y Hacker (2022) enseñaron a la filosofía de las neurociencias a desconfiar de un error preciso: atribuir a una parte lo que sólo se predica del todo. El cerebro no ve ni decide ni cree; ve, decide y cree la persona. Llamen a esto la *falacia mereológica*: ciertas disputas no se resuelven con más datos, porque el problema está en el sujeto de la oración.

Este ensayo aplica esa lección a un solo problema: si una máquina de silicio podría ser consciente. Frente al funcionalismo, que responde que sí en principio, se ha consolidado una réplica atractiva —la conciencia pertenece a los seres vivos, y lo vivo es lo que se produce a sí mismo; el silicio no se autoproduce, luego no siente—. La llamaré *el argumento del sustrato*.

Sostendré que comete un primo de esa falacia: discute **de qué está hecho** el sujeto sin haber fijado **cuál** es. Su criterio —la autopoiesis— no puede fijarlo, y no por vago, sino porque es nítido y señala la unidad equivocada: individúa **células**, no personas. La propia tradición lo advirtió y se movió de la autopoiesis a la autonomía, sin notar que ese movimiento le retira el argumento que quería fundar. Cierro con un fracaso propio: construí una medida de la «firma» de la autopoiesis y, auditada, medía otra cosa. De nada de esto se sigue que el silicio sienta; se sigue que la autopoiesis no es el instrumento que puede decidirlo.

1. El problema y su reconstrucción

Cada época piensa el cerebro con su tecnología dominante, y la metáfora acaba dictando la teoría (Daugman, 2001). La versión filosófica de la metáfora computacional es la realizabilidad múltiple (Putnam, 1967; Fodor, 1974): los estados mentales son estados funcionales, definidos por su rol causal y no por su composición, y realizables en cualquier medio que sostenga las transiciones adecuadas. Su corolario polémico: el sustrato sería ontológicamente irrelevante.

Contra ese corolario convergen dos tradiciones. Searle (1980) sostiene, con la habitación china, que la sintaxis no basta para la semántica, y su naturalismo biológico (1992), que la conciencia es un fenómeno biológico causado por procesos neurofisiológicos. La segunda viene de la biología teórica: Maturana y Varela definen lo vivo por la **autopoiesis**, un sistema que produce y regenera los componentes y la frontera que lo constituyen como unidad (Varela, Maturana y Uribe, 1974; Maturana y Varela, 1980). Thompson (2007) extrae de ahí la continuidad vida-mente; Di Paolo (2005) la corrige desde dentro: la autopoiesis *desnuda* no basta para que algo le *importe* a un sistema —hace falta **adaptividad**, la regulación activa de la propia precariedad, que es la que engendra normatividad—.

Del lado neurocientífico la convergencia es real y el seminario la recorrió: la interocepción muestra cuánto de la experiencia se organiza alrededor de la regulación del estado corporal (Chen et al., 2021; Greenwood y Garfinkel, 2025). Seth (2025) la lleva a su conclusión filosófica: la conciencia sería «una propiedad únicamente de los sistemas vivos (aunque no necesariamente de todos)», y simular algo no es realizarlo —«nada se moja dentro de una computadora que predice el clima»—. Conviene ser exacto con él: sus argumentos, dice, «no refutan» el funcionalismo computacional, «pero lo vuelven menos plausible y menos atractivo»; y rechaza «la afirmación de que sólo la vida basada en carbono puede ser consciente». Su eje es vivo/no-vivo, no carbono/silicio.

En forma canónica, el argumento dice: la conciencia requiere un sujeto, un sistema que sea *uno* y para el cual sus estados tengan valencia; un sistema tiene valencia propia sólo si se produce a sí mismo y puede dejar de existir; ningún sistema de silicio digital se produce a sí mismo; luego ninguno es sujeto de conciencia.

Nótese lo que las dos primeras premisas le exigen a la autopoiesis: no sólo distinguir lo vivo de lo no vivo, sino **individuuar al portador de la experiencia**; dicen que *el sujeto está donde está la auto-producción*. Ahí, y no en la premisa sobre el silicio, se rompe.

2. La unidad equivocada

Preguntemos por la extensión de «sistema autopoietico». La unidad canónica es **la célula**: el caso que Varela, Maturana y Uribe (1974) modelan y el paradigma de la tradición. Y es objetiva: hay un hecho, independiente de nosotros, sobre si una red metabólica produce la membrana que la encierra. El cargo no es de vaguedad; fijada una granularidad, es decidible.

El problema es de aritmética. En mi cuerpo hay del orden de 10^{13} unidades autopoieticas, y **ninguna soy yo**. Si el sujeto está donde está la auto-producción, hay diez billones de sujetos aquí y ninguno escribe este ensayo. El argumento que debía excluir al silencio termina multiplicando sujetos dentro del carbono.

De ahí tres consecuencias. Primera: **el cerebro no es una unidad autopoietica**. No produce sus componentes; los producen sus células. Es un sistema de *segundo orden*: una unidad compuesta de unidades autopoieticas que no es ella misma autopoietica. La teoría localiza al sujeto donde la neurociencia que estos autores invocan no localiza los correlatos.

Segunda: **el hígado es tan autopoietico como el cerebro**: ambos son agregados de células que se autoproducen. Si la auto-producción individuara al sujeto, nada diría por qué éste es el cerebro y no el hígado. Un criterio del sujeto que no distingue entre órganos no es todavía un criterio.

Tercera, y decisiva: para escapar hay que añadir algo —integración causal, clausura operacional— que seleccione una escala entre las anidadas. Pero **eso añadido hace todo el trabajo**, y es lo que el funcionalista concede sin pestañear: es una propiedad de la organización, no del material, y es la que ofrecen las teorías neurobiológicas de la conciencia que el seminario revisó (Mylopoulos, 2022). La auto-producción queda como un epiciclo: no explica nada que la integración causal no explique ya.

La falacia mereológica reaparece invertida: el argumento del sustrato elige un criterio que sólo se satisface en las partes —las células— y pretende que decida sobre el todo. Y que la frontera del sujeto no sea un dato lo enseñó el propio seminario: el grillo de Webb (1996) delega la fonotaxis a un tubo de desfase, materia no viva y sin embargo cognitivamente constitutiva.

3. La tradición ya lo sabía

Esto no es un descubrimiento mío: es la razón por la que Varela abandonó el marco estrecho. En *Principles of Biological Autonomy* (1979) generaliza la autopoiesis hasta la **autonomía**, articulada por la **clausura operacional**, porque la autopoiesis estricta es celular y no llega ni al organismo ni al sistema nervioso; la autonomía sí, pues no exige producción material de componentes, sino una red de procesos que se sostienen recíprocamente.

La clausura operacional es **organizacional**: se define por cómo se encadenan los procesos, no por de qué están hechos. Y una propiedad definida por la forma de la red es, por definición, realizable

en más de un medio. O se queda en la autopoiesis estricta —objetiva, material, de extensión celular, que no individúa al sujeto—, o asciende a la autonomía —que lo individúa, y es organizacional, y no excluye en principio ningún sustrato—. No hay tercera posición donde tenga a la vez las dos cosas que necesita. **El camino que el enactivismo recorrió para poder individuar al sujeto es el mismo que le quita el argumento contra el silicio.**

La teoría ya se advierte a sí misma. Beer (2004), analizando un *glider* del juego de la vida como sistema autopoietico —homenaje explícito a Varela, no refutación—, se detiene en las preguntas previas: si los estados de las celdas «merecen realmente llamarse componentes», si el *glider* «posee realmente una frontera que lo genera y lo constriñe». Observa que la continuidad de su identidad «depende crucialmente de cómo elegimos definir» su organización, y que «estrictamente hablando, ningún sistema es autopoietico si se lo observa durante un intervalo suficientemente largo». Su conclusión es la mía: el criterio es nítido en el caso paradigmático y se vuelve indeterminado justo en los disputados, los únicos donde el argumento lo necesita.

4. Una demostración construida

Debo lo anterior a un fracaso propio, y exhibirlo es más útil que taparlo. Construí dos sistemas que computan bajo una «lesión metabólica» y medí un coeficiente κ de acoplamiento entre cómputo y auto-mantenimiento, que presenté como la *firma operacional* de la autopoiesis: $\kappa \approx 0,88$ para el acoplado, $\kappa = 0,00$ para el desacoplado.

La auditoría muestra tres cosas. $\kappa = 0$ no es un resultado: en esa rama el recurso se repone por estipulación y el parámetro lesionado no aparece en la ecuación; es una identidad aritmética. $\kappa \approx 0,88$ tampoco es un descubrimiento: tiene forma cerrada y recorre todo el rango $[0,1]$ al mover un solo parámetro. Y lo que κ mide, cuando mide algo, es **compartición de un presupuesto de recursos**: un portátil con throttling tendría $\kappa > 0$. Si κ fuera la firma de la autopoiesis, mi computador estaría vivo. Peor: **ninguna de mis dos ramas es autopoietica**, pues en ambas la bomba es un parámetro exógeno que yo lesiono desde fuera; no hay clausura de producción ni la adaptividad que Di Paolo (2005) exige.

Una comprobación lo cierra. Si dejo intacta la máquina y muevo sólo la **frontera** —si cuento la fuente de alimentación como parte del sistema y no como un exterior inagotable—, el mismo «silicio», bajo la misma perturbación, pasa de $\kappa = 0,00$ a $\kappa = 0,70$, del orden del 0,88 del «carbono». κ




Figura 1: *Experimento 10 (reformado)*. La misma máquina, bajo la misma perturbación, con dos fronteras distintas: contando sólo el chip, $\kappa = 0,00$ (inmune); contando también su fuente de alimentación, $\kappa = 0,70$ (24 semillas). El sustrato no cambió: cambió el corte.

no mide una propiedad del sustrato: mide **dónde tracé la frontera**. La medida no descubre unidades; las presupone.

5. La objeción más fuerte, y los límites

La réplica seria es que caricaturizo: Thompson y Di Paolo nunca dijeron que la célula sea el sujeto; hablan de autonomía del organismo. Concedo el hecho y niego que me perjudique: es mi argumento. En cuanto pasa a la autonomía para individuar al organismo, deja de tener un argumento *material* contra el silicio y pasa a tener una teoría *organizacional* de la unidad, compatible con la realizabilidad múltiple. No sostengo que se equivoquen sobre la vida; sostengo que su mejor teoría de la individuación no puede hacer el trabajo anti-funcionalista que se le encarga.

Debo reconocer de quién es lo que sobrevive. La distinción entre identidad *propia* y *prestada* —la del artefacto, cuya identidad «le es acordada» por otro— es de Jonas (1968); que el problema de la individualidad sea «el de justificar cuál separación elegimos entre el gran conjunto de distinciones posibles y arbitrarias» está dicho, con esas palabras, en Barandiaran, Di Paolo y Rohde (2009); y el segundo cuerno de mi dilema lo demostraron antes Villalobos y Dewhurst (2018): una máquina de Turing físicamente implementada satisface la clausura operacional y la determinación estructural del enactivismo clásico, que por tanto, concluyen, «sobre la base del requisito de autonomía por sí solo, no necesita descartar las caracterizaciones computacionales del sistema nervioso». No descubro

la condición de individualidad, ni ese cuerno: míos son el primero —que la autopoiesis estricta individúa células— y la forma de tenaza.

No he mostrado que una máquina sienta, ni que la vida sea irrelevante para la mente: el argumento de Seth (2025) no depende de la premisa que ataco. Tampoco he explicado los qualia; mi argumento es neutral ante el problema difícil, y la neutralidad es deliberada: vale sea el funcionalismo verdadero o falso. Lo mostrado es más modesto y más firme: una de las dos grandes objeciones al funcionalismo se apoya en una unidad que no tiene.

Conclusión

El argumento del sustrato parecía fuerte porque parecía tener dos cosas: un criterio objetivo y material —la auto-producción— y un sujeto al cual aplicarlo. Tiene sólo una a la vez: en sentido estricto señala células —diez billones en un cuerpo, ninguna de ellas yo, y un cerebro que no clasifica—; en el sentido amplio individúa organismos, pero se ha vuelto una propiedad de la organización, y las propiedades de la organización no excluyen sustratos: son la tesis del adversario.

Bennett y Hacker enseñaron que atribuir a la parte lo que es del todo no es un desliz de estilo, sino un error que fabrica pseudoproblemas. El argumento del sustrato es un caso: discute de qué está hecho el sujeto antes de poder decir cuál es. Queda algo, y es lo que me llevo: la diferencia real no es carbono contra silicio, sino automantenimiento **delegado** contra **constitutivo**: un sistema cuyas condiciones de persistencia son internas a la unidad frente a uno que las tiene fuera, en técnicos y redes eléctricas. Pero esa diferencia, como enseñó mi experimento, es relativa al corte; y decidir el corte es la tarea que el debate ha estado saltándose. Mientras la respuesta la ponga quien pregunta, «¿puede el silicio ser consciente?» no es todavía una pregunta: es un recorte a la espera de un argumento.

Bibliografía

Fuentes primarias

- Barandiaran, X. E., Di Paolo, E., & Rohde, M. (2009). *Defining Agency: Individuality, Normativity, Asymmetry, and Spatio-temporality in Action*. *Adaptive Behavior*, 17(5), 367-386.

- Beer, R. D. (2004). *Autopoiesis and Cognition in the Game of Life*. *Artificial Life*, 10(3), 309-326.
- Di Paolo, E. A. (2005). *Autopoiesis, Adaptivity, Teleology, Agency*. *Phenomenology and the Cognitive Sciences*, 4(4), 429-452.
- Fodor, J. A. (1974). *Special Sciences (Or: The Disunity of Science as a Working Hypothesis)*. *Synthese*, 28(2), 97-115.
- Jonas, H. (1968). *Biological Foundations of Individuality*. *International Philosophical Quarterly*, 8(2), 231-251.
- Maturana, H. R., & Varela, F. J. (1980). *Autopoiesis and Cognition: The Realization of the Living*. D. Reidel.
- Putnam, H. (1967). *Psychological Predicates*. En W. H. Capitan & D. D. Merrill (Eds.), *Art, Mind, and Religion*. University of Pittsburgh Press.
- Searle, J. R. (1980). *Minds, Brains, and Programs*. *Behavioral and Brain Sciences*, 3(3), 417-457.
- Searle, J. R. (1992). *The Rediscovery of the Mind*. MIT Press.
- Seth, A. K. (2025). *Conscious artificial intelligence and biological naturalism*. *Behavioral and Brain Sciences*, publicación anticipada en línea, 1-42. <https://doi.org/10.1017/S0140525X25000032>
- Varela, F. J. (1979). *Principles of Biological Autonomy*. North-Holland. [Ed. anotada: E. A. Di Paolo & E. Thompson (Eds.), MIT Press, 2024.]
- Varela, F. J., Maturana, H. R., & Uribe, R. (1974). *Autopoiesis: The Organization of Living Systems, Its Characterization and a Model*. *BioSystems*, 5(4), 187-196.
- Webb, B. (1996). *A Cricket Robot*. *Scientific American*, 275(6), 94-99.

Fuentes secundarias

- Bennett, M. R., & Hacker, P. M. S. (2022). *The Mereological Fallacy in Neuroscience*. En *Philosophical Foundations of Neuroscience* (2ª ed.). Wiley-Blackwell.
- Chen, W. G., y cols. (2021). *The emerging science of interoception: Sensing, integrating, interpreting, and regulating signals within the self*. *Trends in Neurosciences*, 44(1), 3-16. <https://doi.org/10.1016/j.tins.2020.10.007>
- Clark, A. (2015). *Radical Predictive Processing*. *Southern Journal of Philosophy*, 53, 3-27.

- Daugman, J. (2001). *Brain Metaphor and Brain Theory*. En W. Bechtel, P. Mandik & J. Mundale (Eds.), *Philosophy and the Neurosciences: A Reader*. Blackwell.
- Greenwood, B. M., & Garfinkel, S. N. (2025). *Interoceptive mechanisms and emotional processing*. *Annual Review of Psychology*, 76(1), 59-86. <https://doi.org/10.1146/annurev-psych-020924-125202>
- Hinton, G. E. (1992). *How Neural Networks Learn from Experience*. *Scientific American*, 267(3), 144-151.
- Mylopoulos, M. (2022). *Neurobiological theories of consciousness*. En B. D. Young & C. D. Jennings (Eds.), *Mind, Cognition, and Neuroscience: A Philosophical Introduction* (pp. 280-293). Routledge.
- Thompson, E. (2007). *Mind in Life: Biology, Phenomenology, and the Sciences of Mind*. Harvard University Press.